

Universidad de la República
Facultad de Ingeniería

Estimación y Predicción en Series Temporales

Obligatorio 1

Nombre: Uriel Yaffé
Cédula: 5.318.892.6
Fecha: April 19, 2026



I. EJERCICIO 1

A. 1.1

Por la letra sabemos que $x[n] = A + w[n]$, donde $w[n] \sim \mathcal{N}(0, \sigma^2)$. Al sumar una constante a una variable gaussiana desplaza su media pero no cambia su varianza.

$$x[n] \sim \mathcal{N}(A, \sigma^2)$$

Además, como $w[n]$ es ruido blanco gaussiano, las variables $w[n]$ son independientes y por lo tanto $x[n]$ también lo son. Entonces, $\hat{A}$ es una suma de gaussianas independientes, y $\hat{A}$ va a tener la forma de una gaussiana con $\hat{A} \sim \mathcal{N}(\mathbb{E}[\hat{A}], \text{Var}(\hat{A}))$. La media de $\hat{A}$ se calcula

$$\mathbb{E}[\hat{A}] = \mathbb{E}\left[\frac{1}{N} \sum_{n=0}^{N-1} x[n]\right] \stackrel{(*)}{=} \frac{1}{N} \sum_{n=0}^{N-1} \mathbb{E}[x[n]] = \frac{1}{N} \sum_{n=0}^{N-1} A = A$$

(*) Linealidad de la esperanza

$$\text{Para calcular la varianza de } \hat{A}, \quad \text{Var}(\hat{A}) = \text{Var}\left(\frac{1}{N} \sum_{n=0}^{N-1} x[n]\right)$$

$$\text{Usando que } \text{Var}(cX) = c^2 \text{ queda } \text{Var}(\hat{A}) = \frac{1}{N^2} \text{Var}\left(\sum_{n=0}^{N-1} x[n]\right)$$

Como los $x[n]$ son independientes:

$$\text{Var}\left(\sum_{n=0}^{N-1} x[n]\right) = \sum_{n=0}^{N-1} \text{Var}(x[n])$$

Entonces de $\text{Var}(x[n]) = \sigma^2$, se obtiene que $\text{Var}\left(\sum_{n=0}^{N-1} x[n]\right) = N\sigma^2$
Por lo tanto

$$\text{Var}(\hat{A}) = \frac{1}{N^2} (N\sigma^2) = \frac{\sigma^2}{N}$$

Sustituyendo,

$$\hat{A} \sim \mathcal{N}(\mathbb{E}[\hat{A}], \text{Var}(\hat{A})) = \mathcal{N}\left(A, \frac{\sigma^2}{N}\right)$$

B. 1.2

Al realizar $N = 20$ observaciones de $\mathcal{N}(A, \sigma^2)$, con $A = 10$ y $\sigma^2 = 1$, se obtienen un conjunto de muestras $x[n]$.

En una única realización del experimento se obtuvo $\hat{A} = 10.21$, mientras que el estimador $\tilde{A} = x[0]$, la primera observación de las 20 muestras tomó el valor 10.67.

Al ejecutar el código que genera estas realizaciones, muchas veces, se puede observar que el estimador de la media muestral tiende a tomar valores más próximos a A , mientras que $\tilde{A}$ depende significativamente de la varianza. En efecto, al repetir el experimento varias veces, conseguí que tome valores más cercanos a 11 o 9, en lugar de 10. Esto no me ocurrió con la media muestral, ya que, si alguna realización produjo un outlier, su efecto es compensado por el resto de las muestras, reduciendo así la variabilidad del estimador.

En la figura 1 se muestra el histograma correspondiente a los valores obtenidos al repetir el mismo experimento 1000 veces.




Fig. 1. Histograma parte 1.2

En el histograma se comparan los valores de la media muestral de cada experimento con el valor de la primera muestra de cada realización.

Se observa que ambas distribuciones tienen forma, pero la distribución correspondiente a la media muestral $\hat{A}$ es más angosta que la del estimador $\tilde{A}$. Esto se debe a que $\hat{A}$ es el promedio de 20 observaciones independientes, lo que genera que su distribución se asemeje a una Normal con varianza menor, tal como se demostró en la parte 1.1. $\text{Var}(\hat{A}) = \frac{\sigma^2}{20}$.

C. 1.3

El $\text{MSE}(\hat{\theta})$ se calcula como $\mathbb{E}[(\hat{\theta} - \theta)^2] = \text{var}(\hat{\theta}) + \text{bias}^2(\hat{\theta})$.

Del estimador óptimo $\hat{A}$ de la sección 1.1 sabemos que $\mathbb{E}[\hat{A}] = A$ y por lo tanto el $\text{bias}(\hat{A}) = 0$. La varianza es $\frac{\sigma^2}{N}$, por lo tanto, $\text{MSE}(\hat{A}) = \frac{\sigma^2}{N}$.

Para calcular $\text{MSE}(\tilde{A})$, calculamos $\mathbb{E}(\tilde{A})$. Notamos que

$$\tilde{A} = \frac{1}{2N} \sum_{n=0}^{N-1} x[n] = \frac{\hat{A}}{2}$$

Por lo tanto, $\mathbb{E}(\tilde{A}) = \frac{\mathbb{E}(\hat{A})}{2} = \frac{A}{2}$. Entonces, $\text{bias}(\tilde{A}) = \frac{A}{2} - A = -\frac{A}{2}$.

Para calcular la varianza usamos el mismo razonamiento que para la media.

$\tilde{A} = \frac{\hat{A}}{2}$ y usamos la propiedad de la varianza $\text{Var}(cX) = c^2 \text{Var}(X)$.

Entonces, $\text{Var}(\tilde{A}) = \frac{\text{Var}(\hat{A})}{4} = \frac{\sigma^2}{4N}$.

Por lo tanto, $\text{MSE}(\tilde{A}) = \frac{\sigma^2}{4N} + \left(-\frac{A}{2}\right)^2 = \frac{\sigma^2}{4N} + \frac{A^2}{4}$

Las MSEs quedan,

- $\text{MSE}(\hat{A}) = \frac{\sigma^2}{N}$
- $\text{MSE}(\tilde{A}) = \frac{\sigma^2}{4N} + \frac{A^2}{4}$

Al comparar MSE, notamos que $\tilde{A}$ reduce la componente de la varianza pero introduce un sesgo grande ($\frac{A}{2}$), y ese sesgo domina el MSE (cuanto mayor sea N , menor será $\frac{\sigma^2}{N}$ y asumimos que $\frac{A^2}{4} \gg 0$). Por lo tanto, $\tilde{A}$ da un peor MSE en comparación con $\hat{A}$.

II. EJERCICIO 2

A. 2.1

a

Sea $x[n] \sim U(0, \theta)$ y $T = \max\{x[0], x[1], \dots, x[N-1]\}$.

Primero calculamos la función de distribución acumulada de T : $F_T(t) = P(T \leq t)$.

El máximo es menor o igual que t si todas las muestras son menores o iguales que t : $F_T(t) = P(x[0] \leq t, \dots, x[N-1] \leq t)$.

Como las muestras son independientes, $F_T(t) = \prod_{n=0}^{N-1} P(x[n] \leq t)$.

Para una variable uniforme $U(0, \theta)$ se tiene $F_X(t) = \frac{t}{\theta}$, $0 \leq t \leq \theta$.

Entonces

$$F_T(t) = \left(\frac{t}{\theta}\right)^N, \quad 0 \leq t \leq \theta.$$

Derivando obtenemos la densidad, $f_T(t) = \frac{d}{dt} F_T(t)$

$$f_T(t) = \frac{N t^{N-1}}{\theta^N}, \quad 0 \leq t \leq \theta.$$

b

Para calcular la esperanza de T

$$\mathbb{E}[T] = \int_0^\theta t f_T(t) dt.$$

Sustituyendo la densidad calculada, $\mathbb{E}[T] = \int_0^\theta t \left(\frac{N t^{N-1}}{\theta^N}\right) dt$.

$$\mathbb{E}[T] = \frac{N}{\theta^N} \int_0^\theta t^N dt.$$

Sabemos que $\int_0^\theta t^N dt = \frac{\theta^{N+1}}{N+1}$. Entonces,

$$\mathbb{E}[T] = \frac{N}{\theta^N} \frac{\theta^{N+1}}{N+1} = \frac{N}{N+1} \theta$$

c

Para que un estimador sea insesgado, $\mathbb{E}(\hat{\theta}) = \theta, \forall \theta \in \Theta$.

Entonces si como estimador elegimos $\hat{\theta} = a.T$,

$$\mathbb{E}(\hat{\theta}) = \mathbb{E}(a.T) = a.\mathbb{E}(T) = a.\frac{N}{N+1}\theta$$

Para que sea insesgado, la constante a debería ser, $\mathbb{E}(\hat{\theta}) =$

$$a.\frac{N}{N+1}\theta = \theta \longrightarrow a = \frac{N+1}{N}$$

$$\hat{\theta} = \frac{N+1}{N}.T$$

B. 2.2

Sabemos que $x[n] \sim U(0, \theta)$ y la esperanza de una variable uniforme en $(0, \theta)$ es $\mathbb{E}[x[n]] = \frac{\theta}{2}$

Consideramos la media muestral

$$\bar{x} = \frac{1}{N} \sum_{n=0}^{N-1} x[n]$$

Calculamos la esperanza usando linealidad:

$$\mathbb{E}[\bar{x}] = \frac{1}{N} \sum_{n=0}^{N-1} \mathbb{E}[x[n]]$$

$$\mathbb{E}[\bar{x}] = \frac{1}{N} \cdot N \cdot \frac{\theta}{2} = \frac{\theta}{2}$$

Entonces la media muestral no es un estimador insesgado de θ .

Para hallar uno insesgado, realizamos lo mismo que en la parte anterior, multiplicamos el estimador de la media muestral por una constante.

Entonces, $a.\mathbb{E}[\bar{x}] = a \cdot \frac{\theta}{2} = \theta$, lo que nos queda que $a = 2$

Por lo tanto, un estimador insesgado de θ basado en la media muestral es

$$\check{\theta} = 2\bar{x} = \frac{2}{N} \sum_{n=0}^{N-1} x[n]$$

C. 2.3

La condición de regularidad de Cramér-Rao $p(x; \theta)$ tiene que cumplir,

$$\mathbb{E}_x \left[\frac{\partial \log p(x; \theta)}{\partial \theta} \right] = 0, \forall \theta$$

Para una variable uniforme, $U(0, \theta)$, la distribución acumulada es $F_X = \frac{t}{\theta}$ y, por lo tanto, su densidad $p(x, \theta) = \frac{1}{\theta}$ para $0 \leq x \leq \theta$.

El logaritmo de la densidad queda,

$$\log p(x; \theta) = \log \left(\frac{1}{\theta} \right) = -\log \theta$$

Derivando respecto a θ :

$$\frac{\partial}{\partial \theta} \log p(x; \theta) = -\frac{1}{\theta}$$

Ahora calculamos la esperanza:

$$\mathbb{E} \left[\frac{\partial}{\partial \theta} \log p(x; \theta) \right] = \int_0^\theta \left(-\frac{1}{\theta} \right) \frac{1}{\theta} dx = -\frac{1}{\theta^2} \int_0^\theta dx = -\frac{1}{\theta^2} \theta = -\frac{1}{\theta}$$

Entonces

$$\mathbb{E} \left[\frac{\partial}{\partial \theta} \ln p(x; \theta) \right] = -\frac{1}{\theta} \neq 0$$

Por lo tanto, la condición de regularidad de Cramér-Rao no se cumple para la distribución uniforme $U(0, \theta)$.

D. 2.4

Recordando $\hat{\theta} = \frac{N-1}{N}T$, por lo tanto su varianza es $\text{Var}(\hat{\theta}) = \left(\frac{N-1}{N}\right)^2 \cdot \text{Var}(T)$

Ahora queda calcular la varianza de T . Sabemos que $\text{Var}(T) = \mathbb{E}(T^2) - \mathbb{E}(T)^2$. En la sección 2.1.b ya calculamos $\mathbb{E}(T) = \frac{N}{N+1} \cdot \theta$.

Calculamos ahora $\mathbb{E}[T^2]$:




Fig. 2. Verificación Experimental de $\hat{\theta}$ y $\check{\theta}$

$$\mathbb{E}[T^2] = \int_0^\theta t^2 f_T(t) dt$$

Sustituyendo $f_T(t)$:

$$\mathbb{E}[T^2] = \int_0^\theta t^2 \frac{N t^{N-1}}{\theta^N} dt = \frac{N}{\theta^N} \int_0^\theta t^{N+1} dt$$

Sabemos que

$$\int_0^\theta t^{N+1} dt = \frac{\theta^{N+2}}{N+2}$$

Entonces

$$\mathbb{E}[T^2] = \frac{N}{\theta^N} \frac{\theta^{N+2}}{N+2} = \frac{N}{N+2} \theta^2$$

Por lo tanto,

$$\text{Var}(T) = \frac{N}{N+2} \theta^2 - \left(\frac{N}{N+1} \theta \right)^2 = \theta^2 \left(\frac{N}{N+2} - \frac{N^2}{(N+1)^2} \right)$$

Resolviendo la expresión:

$$\text{Var}(T) = \frac{N\theta^2}{(N+1)^2(N+2)}$$

Sustituyendo al estimador

$$\text{Var}(\hat{\theta}) = \left(\frac{N+1}{N} \right)^2 \text{Var}(T) = \left(\frac{N+1}{N} \right)^2 \frac{N\theta^2}{(N+1)^2(N+2)}$$

Simplificando:

$$\text{Var}(\hat{\theta}) = \frac{\theta^2}{N(N+2)}$$

E. 2.5

En la Figura 2 se pueden ver los histogramas de los estimadores $\hat{\theta}$ y $\check{\theta}$ a partir de 10 000 realizaciones, para $N = \{1, 2, 4, 100\}$.

Se observa que para $N = 1$ ambos estimadores coinciden. Como el vector $x[n]$ tiene un único elemento,

$$\check{\theta} = \frac{2}{N} \sum_{n=0}^{N-1} x[n] = 2x[0]$$

y

$$\hat{\theta} = \frac{N+1}{N} T = 2 \max\{x[0]\} = 2x[0].$$

Por lo tanto, en este caso ambos estimadores son equivalentes.

A medida que N crece, ambas distribuciones se concentran alrededor del valor verdadero $\theta = 10$, lo cual evidencia que ambos estimadores son insesgados.

Sin embargo, se observan diferencias en la dispersión. El estimador $\check{\theta}$ (naranja), basado en el promedio muestral, presenta una distribución más simétrica y con menor dispersión para valores moderados de N .

Por otro lado, el estimador $\hat{\theta}$ (azul), basado en el máximo, presenta una mayor variabilidad para N pequeños y una distribución asimétrica, concentrándose hacia valores cercanos a θ desde la derecha. Esto se debe a que el máximo muestral tiende a subestimar θ , y la corrección $\frac{N+1}{N}$ compensa este efecto en media, pero no elimina la asimetría.

A medida que N aumenta, la varianza de ambos estimadores decrece, aunque $\hat{\theta}$ lo hace más rápidamente, en concordancia con la sección 2.4

$$\text{Var}(\hat{\theta}) = \frac{\theta^2}{N(N+2)}.$$

Con $N=100$ se puede notar que la varianza de $\hat{\theta}$ es mucho menor que la de $\check{\theta}$. En la Tabla II-E se compara tanto la media y varianza de los experimentos.

Ambos estimadores son insesgados y consistentes, pero $\hat{\theta}$ resulta más eficiente para valores grandes de N , mientras que $\check{\theta}$ presenta un comportamiento más estable para tamaños muestrales pequeños.

N	$\mathbb{E}[\hat{\theta}]$	$\text{Var}(\hat{\theta})$	$\mathbb{E}[\check{\theta}]$	$\text{Var}(\check{\theta})$
1	9.8882	32.5823	9.8882	32.5823
2	9.9807	12.5468	9.9898	16.6791
4	9.9966	4.1574	10.0248	8.4844
100	10.0003	0.0097	9.9991	0.3323

Teniendo en cuenta los resultados obtenidos en el ejercicio 1.2, se observa que en ambos casos los estimadores considerados son insesgados.

La reducción de varianza al utilizar la media muestral es considerablemente más significativa en el modelo gaussiano que en el caso uniforme.

En el caso gaussiano, cada observación contiene información sobre el parámetro A , y dicha información se encuentra distribuida en todas las muestras. Como consecuencia,

al promediar se reduce el efecto del ruido, obteniéndose una varianza que decrece como σ^2/N . Además, la media muestral es el estimador de mínima varianza insesgado (MVU), por lo que no existe otro estimador insesgado con menor varianza.

En cambio, en el modelo uniforme $U(0, \theta)$, la información sobre el parámetro θ está concentrada en el extremo superior del soporte. Por esto, el máximo muestral es muy informativo, mientras que la media no captura dicha información. En consecuencia, la reducción de varianza al promediar no es tan fuerte como en el caso gaussiano.

III. EJERCICIO 3

A. 3.1

Con $x[n] = A \cos(2\pi f_0 n + \phi) + w[n]$, $n = 0, 1, \dots, N - 1$. El estimador $\theta = [\cos \phi, \sin \phi]^T$ se puede formularse como un modelo lineal $X = H\theta + W$.

Utilizando la identidad trigonométrica

$$\cos(\alpha + \beta) = \cos \alpha \cos \beta - \sin \alpha \sin \beta,$$

se puede reescribir $x[n]$ como

$$x[n] = A \cos(2\pi f_0 n) \cos \phi - A \sin(2\pi f_0 n) \sin \phi + w[n].$$

Definiendo el vector de parámetros

$$\theta = \begin{bmatrix} \cos \phi \\ \sin \phi \end{bmatrix} \quad y \quad X = H\theta + W,$$

donde

$$X = \begin{bmatrix} x[0] \\ x[1] \\ \vdots \\ x[N-1] \end{bmatrix}, \quad W = \begin{bmatrix} w[0] \\ w[1] \\ \vdots \\ w[N-1] \end{bmatrix},$$

Para calcular la matriz H , despejamos

$$H\theta = A \cos(2\pi f_0 n) \cos \phi - A \sin(2\pi f_0 n) \sin \phi$$

Entonces, para la primera fila de H ,

$$H_{00} \cdot \cos(\phi) + H_{01} \cdot \sin(\phi) = A \cos(2\pi f_0 0) \cos \phi - A \sin(2\pi f_0 0) \sin \phi$$

Por lo tanto obtenemos que

$$H_{00} = A \cos(2\pi f_0 0) \quad y \quad H_{01} = -A \sin(2\pi f_0 0)$$

Planteando lo mismo para la segunda fila

$$H_{10} \cdot \cos(\phi) + H_{11} \cdot \sin(\phi) = A \cos(2\pi f_0 1) \cos \phi - A \sin(2\pi f_0 1) \sin \phi$$

$$\rightarrow H_{10} = A \cos(2\pi f_0 1) \quad y \quad H_{11} = -A \sin(2\pi f_0 1)$$

Siguiendo el mismo procedimiento, la matriz H está dada por

$$H = \begin{bmatrix} A \cos(2\pi f_0 \cdot 0) & -A \sin(2\pi f_0 \cdot 0) \\ A \cos(2\pi f_0 \cdot 1) & -A \sin(2\pi f_0 \cdot 1) \\ \vdots & \vdots \\ A \cos(2\pi f_0 (N-1)) & -A \sin(2\pi f_0 (N-1)) \end{bmatrix}.$$

B. 3.2

Considerando el modelo lineal, el estimador de máxima verosimilitud coincide con el estimador de mínimos cuadrados y está dado por

$$\hat{\theta} = (H^T H)^{-1} H^T X.$$

Este estimador es insesgado, ya que

$$\mathbb{E}[\hat{\theta}] = (H^T H)^{-1} H^T \mathbb{E}[X] = (H^T H)^{-1} H^T H\theta = \theta.$$

Partiendo del estimador

$$\hat{\theta} = (H^T H)^{-1} H^T X = (H^T H)^{-1} H^T (H\theta + W) = \theta + (H^T H)^{-1} H^T W.$$

Por lo tanto,

$$\hat{\theta} - \theta = (H^T H)^{-1} H^T W.$$

La matriz de covarianza es:

$$\text{Cov}(\hat{\theta}) = \mathbb{E}[(\hat{\theta} - \theta)(\hat{\theta} - \theta)^T]$$

$$= \mathbb{E}[(H^T H)^{-1} H^T W W^T H (H^T H)^{-1}].$$

$(H^T H)^{-1} H^T$ es constante,

$$= (H^T H)^{-1} H^T \mathbb{E}[W W^T] H (H^T H)^{-1}.$$

Como $W \sim \mathcal{N}(0, \sigma^2 I)$,

$$\mathbb{E}[W W^T] = \sigma^2 I,$$

entonces:

$$\text{Cov}(\hat{\theta}) = \sigma^2 (H^T H)^{-1} H^T H (H^T H)^{-1} = \sigma^2 (H^T H)^{-1}.$$

Viendo si la inversa de la matriz de Fisher coincide con la matriz de Covarianza verificamos que el estimador es eficiente.

Como la densidad de X tiene la forma de una Gausseana con media $H\theta$ y la varianza del ruido,

$$X \sim \mathcal{N}(H\theta, \sigma^2 I),$$

por lo que la log-verosimilitud está dada por

$$\ell(\theta) = -\frac{1}{2\sigma^2} (X - H\theta)^T (X - H\theta) - \frac{N}{2} \log(2\pi\sigma^2)$$

Derivando respecto a θ :

$$\nabla_{\theta} \ell(\theta) = \frac{1}{\sigma^2} H^T (X - H\theta).$$

El Hessiano es:

$$\nabla_{\theta}^2 \ell(\theta) = -\frac{1}{\sigma^2} H^T H.$$

La matriz de información de Fisher es:

$$\mathcal{I}(\theta) = -\mathbb{E}[\nabla_{\theta}^2 \ell(\theta)] = \frac{1}{\sigma^2} H^T H.$$

y

$$H^T H = A^2 \begin{bmatrix} \sum \cos^2(2\pi f_0 n), & -\sum \cos(2\pi f_0 n) \sin(2\pi f_0 n) \\ -\sum \cos(2\pi f_0 n) \sin(2\pi f_0 n), & \sum \sin^2(2\pi f_0 n) \end{bmatrix}$$

Usando identidades trigonométricas:

$$\sum_{n=0}^{N-1} \cos^2(2\pi f_0 n) = \sum_{n=0}^{N-1} \sin^2(2\pi f_0 n) = \frac{N}{2},$$

$$\sum_{n=0}^{N-1} \cos(2\pi f_0 n) \sin(2\pi f_0 n) = 0,$$

se obtiene:

$$H^T H = \frac{A^2 N}{2} I \longrightarrow (H^T H)^{-1} = \frac{2}{A^2 N} I$$

por lo que la cota de Cramér-Rao está dada por

$$\text{CRB} = \mathcal{I}^{-1}(\theta) = \sigma^2 (H^T H)^{-1} = \sigma^2 \cdot \frac{2}{A^2 N} I$$

Dado que la covarianza del estimador coincide con la cota de Cramér-Rao, $\hat{\theta}$ es un estimador eficiente.

C. 3.4

En el modelo lineal se tiene que

$$\hat{\theta} = \theta + (H^T H)^{-1} H^T W,$$

por lo que $\hat{\theta}$ es gaussiano, ya que $(H^T H)^{-1} H^T W$ es una transformación lineal del ruido gaussiano W .

Sin embargo, el estimador de fase se define como

$$\hat{\phi} = \arctan \left(\frac{\hat{\theta}_2}{\hat{\theta}_1} \right),$$

que es una transformación no lineal de $\hat{\theta}$.

Debido a esta no linealidad, la varianza de $\hat{\phi}$ ya no coincide exactamente con la cota de Cramér-Rao para ϕ . Es decir, aunque $\hat{\theta}$ sea eficiente para estimar θ , la transformación no lineal $\arctan(\cdot)$ introduce una distorsión que impide preservar dicha eficiencia.

Por lo tanto, $\hat{\phi}$ no es eficiente.

Para verificar si es asintóticamente eficiente, analizamos su comportamiento para N grande.

Se tiene que:

$$\hat{\theta} \sim \mathcal{N} \left(\theta, \frac{2\sigma^2}{A^2 N} I \right),$$

por lo que:

$$\hat{\theta} \rightarrow \theta \quad \text{cuando } N \rightarrow \infty.$$

Dado que $\hat{\phi} = g(\hat{\theta})$ con $g(\cdot)$ una función suave, puede aproximarse mediante Taylor en torno a θ :

$$g(\hat{\theta}) \approx g(\theta) + \nabla g(\theta)^T (\hat{\theta} - \theta).$$

El gradiente es:

$$\nabla g(\theta) = \frac{1}{\theta_1^2 + \theta_2^2} \begin{bmatrix} -\theta_2 \\ \theta_1 \end{bmatrix} = \begin{bmatrix} -\sin \phi \\ \cos \phi \end{bmatrix}.$$

Entonces:

$$\hat{\phi} \approx \phi + [-\sin \phi, \cos \phi]^T (\hat{\theta} - \theta).$$

Tomando esperanza:

$$\mathbb{E}[\hat{\phi}] \approx \phi,$$

por lo que el estimador es asintóticamente insesgado.

La varianza viene dada por:

$$\text{Var}(\hat{\phi}) \approx \nabla g(\theta)^T \text{Cov}(\hat{\theta}) \nabla g(\theta).$$

Sustituyendo:

$$= \frac{2\sigma^2}{A^2 N} (\sin^2 \phi + \cos^2 \phi) = \frac{2\sigma^2}{A^2 N}.$$

Dado que la cota de Cramér-Rao para ϕ es:

$$\text{CRLB}(\phi) = \frac{2\sigma^2}{A^2 N},$$

se concluye que:

$$\text{Var}(\hat{\phi}) \rightarrow \text{CRLB}(\phi) \quad \text{cuando } N \rightarrow \infty.$$

Por lo tanto, $\hat{\phi}$ es asintóticamente eficiente.

D. 3.5

1) *a:* Los resultados muestran que las medias empíricas de $\widehat{\cos \phi}$ y $\widehat{\sin \phi}$ coinciden con sus valores verdaderos, lo que indica que ambos estimadores son insesgados.

Las varianzas empíricas coinciden con la expresión teórica:

$$\text{Cov}(\hat{\theta}) = \sigma^2 (H^T H)^{-1}.$$

Se observa además que dichas varianzas decrecen proporcionalmente a $1/N$, en concordancia con lo obtenido analíticamente en la Parte B.

En las Tablas I y II se presentan los valores esperados y las varianzas de los estimadores para distintos valores de N .

N	$\mathbb{E}[\widehat{\cos \phi}]$	Var	Var teórica
100	0.8652	1.01×10^{-1}	1.0×10^{-1}
500	0.8665	2.03×10^{-2}	2.0×10^{-2}
1000	0.8634	1.01×10^{-2}	1.0×10^{-2}
5000	0.8653	2.03×10^{-3}	2.0×10^{-3}
10000	0.8655	1.03×10^{-3}	1.0×10^{-3}

TABLE I
ESTIMADOR DE $\cos \phi$

N	$\mathbb{E}[\widehat{\sin \phi}]$	Var	Var teórica
100	0.5016	1.02×10^{-1}	1.0×10^{-1}
500	0.5009	2.04×10^{-2}	2.0×10^{-2}
1000	0.4995	1.03×10^{-2}	1.0×10^{-2}
5000	0.5005	1.99×10^{-3}	2.0×10^{-3}
10000	0.5007	9.91×10^{-4}	1.0×10^{-3}

TABLE II
ESTIMADOR DE $\sin \phi$

En la Figura 3 se observa que el comportamiento de los estimadores lineales sigue de cerca el valor verdadero, tanto para valores grandes como pequeños de N . En particular, se verifica la disminución de la varianza a medida que aumenta el número de muestras.




Fig. 3. Varianza de los estimadores lineales en función de N

2) : La estimación de la fase introduce una no linealidad:

$$\hat{\phi} = \arctan \left(\frac{\hat{\theta}_2}{\hat{\theta}_1} \right).$$

Esta se obtiene a partir de las estimaciones de $\widehat{\cos \phi}$ y $\widehat{\sin \phi}$.

Para evaluar su desempeño, se calcula el error angular entre el estimador y el valor real, y a partir de este se estima su varianza.

Si bien el estimador de fase es no lineal, los resultados muestran que su varianza disminuye al aumentar el número de muestras, como se observa en la Tabla III.

N	$\text{Var}(\hat{\phi})$
100	1.17×10^{-1}
500	2.09×10^{-2}
1000	1.04×10^{-2}
5000	2.04×10^{-3}
10000	9.99×10^{-4}

TABLE III
VARIANZA EMPÍRICA DEL ESTIMADOR $\hat{\phi}$

Además, se observa que la varianza decrece aproximadamente como $1/N$, lo cual coincide con el comportamiento teórico esperado. Para valores grandes de N , el efecto de la no linealidad se vuelve despreciable y el estimador se comporta de manera aproximadamente lineal en torno al valor verdadero.

En consecuencia, $\hat{\phi}$ no es eficiente en general, pero sí asintóticamente eficiente, ya que su varianza tiende a alcanzar la cota de Cramér-Rao cuando $N \rightarrow \infty$.

3) : En esta parte se compara la varianza empírica del estimador de fase $\hat{\phi}$ con la cota de Cramér-Rao obtenida en la Parte B. La cota está dada por:

$$\text{CRLB}(\phi) = \frac{2\sigma^2}{A^2 N}.$$

Como se observa en la Tabla IV, la varianza del estimador es mayor que la cota de Cramér-Rao para valores finitos de N , lo cual confirma que $\hat{\phi}$ no es eficiente en general.

N	$\text{Var}(\hat{\phi})$	$\text{CRLB}(\phi)$	Var/CRLB
100	1.17×10^{-1}	1.00×10^{-1}	1.17
500	2.09×10^{-2}	2.00×10^{-2}	1.05
1000	1.04×10^{-2}	1.00×10^{-2}	1.04
5000	2.04×10^{-3}	2.00×10^{-3}	1.02
10000	9.99×10^{-4}	1.00×10^{-3}	1.00

TABLE IV
COMPARACIÓN ENTRE LA VARIANZA EMPÍRICA DE $\hat{\phi}$ Y LA COTA DE CRAMÉR-RAO

Sin embargo, el cociente $\text{Var}(\hat{\phi})/\text{CRLB}$ tiende a 1 a medida que N aumenta. Esto indica que la varianza del estimador converge a la cota, verificando que $\hat{\phi}$ es asintóticamente eficiente.

Este comportamiento se debe a que, para grandes valores de N , el efecto de la no linealidad en la estimación de la fase se vuelve despreciable, y el estimador puede aproximarse localmente como una transformación lineal del estimador $\hat{\theta}$.