

Universidad de la República
Facultad de Ingeniería

Estimación y Predicción en Series Temporales

Obligatorio 1

Nombre: Uriel Yaffé
Cédula: 5.318.892.6
Fecha: May 18, 2026



I. EJERCICIO 1

A.

Considere el modelo

$$x[n] = \sum_{k=0}^{p-1} A_k n^k + w[n], \quad n = 1, 2, \dots, N$$

con

$$w[n] \sim \mathcal{N}(0, \sigma^2)$$

y las muestras de ruido son independientes.

Definimos el vector,

$$\mathbf{x} = \begin{bmatrix} x[1] \\ x[2] \\ \vdots \\ x[N] \end{bmatrix}$$

el vector de parámetros

$$\boldsymbol{\theta} = \begin{bmatrix} A_0 \\ A_1 \\ \vdots \\ A_{p-1} \end{bmatrix},$$

y el vector de ruido

$$\mathbf{w} = \begin{bmatrix} w[1] \\ w[2] \\ \vdots \\ w[N] \end{bmatrix}.$$

Entonces el modelo puede escribirse como

$$\mathbf{x} = \mathbf{H}\boldsymbol{\theta} + \mathbf{w}$$

donde

$$\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$$

Donde

$$\mathbf{H}\boldsymbol{\theta}_{i=1,j} = A_0 \cdot 1^0 + A_1 \cdot 1^1 + \dots + A_{p-1} 1^{p-1}$$

Siguiendo la lógica de lo anterior, la matriz que

$$\mathbf{H} = \begin{bmatrix} 1 & 1 & 1^2 & \dots & 1^{p-1} \\ 1 & 2 & 2^2 & \dots & 2^{p-1} \\ 1 & 3 & 3^2 & \dots & 3^{p-1} \\ \vdots & \vdots & \vdots & \dots & \vdots \\ 1 & N & N^2 & \dots & N^{p-1} \end{bmatrix}.$$

Como el ruido es gaussiano blanco y el modelo lineal, el estimador de máxima verosimilitud coincide con el estimador de mínimos cuadrados y está dado por

$$\hat{\boldsymbol{\theta}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{x}.$$

La función de verosimilitud es

$$p(\mathbf{x}; \boldsymbol{\theta}) = \frac{1}{(2\pi\sigma^2)^{N/2}} \exp \left(-\frac{1}{2\sigma^2} (\mathbf{x} - \mathbf{H}\boldsymbol{\theta})^T (\mathbf{x} - \mathbf{H}\boldsymbol{\theta}) \right).$$

Y la matriz de información de Fisher es

$$\mathbf{I}(\boldsymbol{\theta}) = \frac{1}{\sigma^2} \mathbf{H}^T \mathbf{H}$$

$$\mathbf{H}^T \mathbf{H} = \begin{bmatrix} \sum_{n=1}^N n^0 & \sum_{n=1}^N n^1 & \sum_{n=1}^N n^2 & \dots & \sum_{n=1}^N n^{p-1} \\ \sum_{n=1}^N n^1 & \sum_{n=1}^N n^2 & \sum_{n=1}^N n^3 & \dots & \sum_{n=1}^N n^p \\ \sum_{n=1}^N n^2 & \sum_{n=1}^N n^3 & \sum_{n=1}^N n^4 & \dots & \sum_{n=1}^N n^{p+1} \\ \vdots & \vdots & \vdots & \dots & \vdots \\ \sum_{n=1}^N n^{p-1} & \sum_{n=1}^N n^p & \sum_{n=1}^N n^{p+1} & \dots & \sum_{n=1}^N n^{2p-2} \end{bmatrix}$$

$$(\mathbf{H}^T \mathbf{H})_{ij} = \sum_{n=1}^N n^{i+j-2}.$$

Además,

$$\mathbf{H}^T \mathbf{x} = \begin{bmatrix} \sum_{n=1}^N x[n] \\ \sum_{n=1}^N n x[n] \\ \sum_{n=1}^N n^2 x[n] \\ \vdots \\ \sum_{n=1}^N n^{p-1} x[n] \end{bmatrix}.$$

Por lo tanto, el estimador MVU es:

$$\hat{\boldsymbol{\theta}} = (\mathbf{H}^T \mathbf{H})^{-1} \begin{bmatrix} \sum_{n=1}^N x[n] \\ \sum_{n=1}^N n x[n] \\ \sum_{n=1}^N n^2 x[n] \\ \vdots \\ \sum_{n=1}^N n^{p-1} x[n] \end{bmatrix}$$

y la matriz de información de Fisher es

$$\mathbf{I}(\boldsymbol{\theta}) = \frac{1}{\sigma^2} \begin{bmatrix} \sum_{n=1}^N n^0 & \sum_{n=1}^N n^1 & \dots & \sum_{n=1}^N n^{p-1} \\ \sum_{n=1}^N n^1 & \sum_{n=1}^N n^2 & \dots & \sum_{n=1}^N n^p \\ \vdots & \vdots & \dots & \vdots \\ \sum_{n=1}^N n^{p-1} & \sum_{n=1}^N n^p & \dots & \sum_{n=1}^N n^{2p-2} \end{bmatrix}$$

Generalizando

$$I_{ij} = \frac{1}{\sigma^2} \sum_{n=1}^N n^{i+j-2} = \frac{1}{\sigma^2} (\mathbf{H}^T \mathbf{H})_{ij}.$$

B.

Se realizó el experimento para $p = 4$ y se estimaron los parámetros del modelo. Los coeficientes verdaderos utilizados fueron:

$$[-9.0, 0.73, -0.016, 0.0001]$$

mientras que los coeficientes estimados obtenidos fueron:

$$[-9.12974462, 0.775439746, -0.0174174486, 0.000110616306]$$

Se observa que los valores estimados son muy similares a los verdaderos, lo que confirma el buen desempeño del estimador MVU con presencia de ruido gaussiano.




Fig. 1. Comparación entre el polinomio verdadero y el polinomio estimado para $p = 4$.

Aunque el conjunto de nuestras observadas presenta una gran dispersión alrededor de la curva verdadera, el polinomio estimado sigue de cerca al verdadero. Esto muestra que, aunque haya mucha varianza en los datos, con una cantidad suficiente de muestras el estimador es consistente.

Además, teóricamente, al aumentar el número de muestras N , la varianza del estimador disminuye y la estimación converge al verdadero valor de los parámetros.

Como se mostró en el obligatorio anterior, el estimador eficiente es el de mínimos cuadrados y alcanza la cota de Cramér-Rao y la matriz de Fisher es la inversa de la matriz de Covarianza.

$Cov(\hat{\theta}) = \sigma^2 (\mathbf{H}^T \mathbf{H})^{-1}$, entonces al aumentar N , $(\mathbf{H}^T \mathbf{H})^{-1}$ baja.

Para probar, se aumentó el número de muestras de $N = 100$ a $N = 200$. Se ve una estimación casi perfecta con una dispersión de datos mucho menor a la estimación con $N = 100$.




Fig. 2. Comparación de polinomios verdadero y estimado con $N=200$.

II. EJERCICIO 2

A. 2.1

$$x[n] = A s[n] + w[n], \quad n = 0, 1, \dots, N-1$$

con

$$w[n] \sim \mathcal{N}(0, \sigma^2)$$

Como el ruido es gaussiano blanco e independiente

$$x[n] \sim \mathcal{N}(A s[n], \sigma^2)$$

Por lo tanto, la función de verosimilitud es:

$$p(x; A) = \prod_{n=0}^{N-1} \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x[n] - A s[n])^2}{2\sigma^2}\right)$$

$$\ln p(x; A) = -\frac{N}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{n=0}^{N-1} (x[n] - A s[n])^2$$

El estimador MLE maximiza la log-verosimilitud, derivando respecto de A :

$$\frac{\ln p(x; A)}{dA} = \frac{1}{\sigma^2} \sum_{n=0}^{N-1} s[n](x[n] - A s[n])$$

Igualando a cero:

$$\sum_{n=0}^{N-1} s[n]x[n] - A \sum_{n=0}^{N-1} s^2[n] = 0$$

Despejando A :

$$\hat{A}_{\text{MLE}} = \frac{\sum_{n=0}^{N-1} s[n]x[n]}{\sum_{n=0}^{N-1} s^2[n]}$$

B. 2.2

A partir de

$$\hat{A}_{\text{MLE}} = \frac{\sum_{n=0}^{N-1} s[n]x[n]}{\sum_{n=0}^{N-1} s^2[n]}$$

y utilizando el modelo

$$x[n] = A s[n] + w[n]$$

Se sustituye $x[n]$

$$\hat{A}_{\text{MLE}} = \frac{\sum_{n=0}^{N-1} s[n](A s[n] + w[n])}{\sum_{n=0}^{N-1} s^2[n]}$$

$$\hat{A}_{\text{MLE}} = A + \frac{\sum_{n=0}^{N-1} s[n]w[n]}{\sum_{n=0}^{N-1} s^2[n]}$$

Como $w[n] \sim \mathcal{N}(0, \sigma^2)$ son gaussianas independientes, entonces la combinación lineal

$$\sum_{n=0}^{N-1} s[n]w[n]$$

también es gaussiana con:

$$\mathbb{E} \left[\sum s[n]w[n] \right] = 0$$

y

$$\text{Var} \left(\sum s[n]w[n] \right) = \sigma^2 \sum_{n=0}^{N-1} s^2[n]$$

Por lo tanto:

$$\hat{A}_{\text{MLE}} \sim \mathcal{N} \left(A, \frac{\sigma^2}{\sum_{n=0}^{N-1} s^2[n]} \right)$$

La densidad de probabilidad es:

$$p(\hat{A}; A) = \frac{1}{\sqrt{2\pi \frac{\sigma^2}{\sum s^2[n]}}} \exp \left(-\frac{(\hat{A} - A)^2}{2 \frac{\sigma^2}{\sum s^2[n]}} \right)$$

C. 2.3

$$\hat{A}_{\text{MLE}} \sim \mathcal{N} \left(A, \frac{\sigma^2}{\sum_{n=0}^{N-1} s^2[n]} \right)$$

El estimador es insesgado, ya que: $\mathbb{E}[\hat{A}_{\text{MLE}}] = A$

La varianza del estimador es

$$\text{Var}(\hat{A}_{\text{MLE}}) = \frac{\sigma^2}{\sum_{n=0}^{N-1} s^2[n]}$$

A medida que $N \rightarrow \infty$,

$$\sum_{n=0}^{N-1} s^2[n] \rightarrow \infty$$

Entonces,

$$\text{Var}(\hat{A}_{\text{MLE}}) \rightarrow 0 \quad \wedge \quad \hat{A}_{\text{MLE}} \rightarrow A$$

Esto significa que, al aumentar la cantidad de observaciones, la incertidumbre del estimador disminuye y la distribución de $\hat{A}_{\text{MLE}}$ se concentra cada vez más alrededor del verdadero valor A .

III. EJERCICIO 3

A. 3.1

Se considera el modelo

$$x[n] = A + Bn + w[n], \quad 0 \leq n \leq N-1$$

donde

$$w[n] \sim \mathcal{N}(0, \sigma^2)$$

Definimos el vector de observaciones:

$$\mathbf{x} = \begin{bmatrix} x[0] \\ x[1] \\ \vdots \\ x[N-1] \end{bmatrix}$$

y

$$\boldsymbol{\theta} = \begin{bmatrix} A \\ B \end{bmatrix}$$

y la matriz queda

$$\mathbf{H} = \begin{bmatrix} 1 & 0 \\ 1 & 1 \\ 1 & 2 \\ \vdots & \vdots \\ 1 & N-1 \end{bmatrix}$$

Entonces el modelo puede escribirse como

$$\mathbf{x} = \mathbf{H}\boldsymbol{\theta} + \mathbf{w}$$

donde

$$\mathbf{w} \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$$

Como el ruido es gaussiano blanco, el estimador de máxima verosimilitud coincide con el estimador de mínimos cuadrados

$$\hat{\boldsymbol{\theta}} = (\mathbf{H}^T \mathbf{H})^{-1} \mathbf{H}^T \mathbf{x}$$

Calculando:

$$\mathbf{H}^T \mathbf{H} = \begin{bmatrix} N & \sum n \\ \sum n & \sum n^2 \end{bmatrix} \quad y \quad \mathbf{H}^T \mathbf{x} = \begin{bmatrix} \sum x[n] \\ \sum n x[n] \end{bmatrix}$$

Con

$$\sum_{n=0}^{N-1} n = \frac{N(N-1)}{2} \quad y \quad \sum_{n=0}^{N-1} n^2 = \frac{N(N-1)(2N-1)}{6}$$

Desarrollando,

$$(\mathbf{H}^T \mathbf{H})^{-1} = \frac{1}{N \sum n^2 - (\sum n)^2} \begin{bmatrix} \sum n^2 & -\sum n \\ -\sum n & N \end{bmatrix}$$

$$\hat{\boldsymbol{\theta}} = \frac{1}{N \sum n^2 - (\sum n)^2} \begin{bmatrix} (\sum n^2) (\sum x[n]) - (\sum n) (\sum n x[n]) \\ -(\sum n) (\sum x[n]) + N (\sum n x[n]) \end{bmatrix}$$

Por lo tanto:

$$\hat{A} = \frac{(\sum n^2) (\sum x[n]) - (\sum n) (\sum n x[n])}{N \sum n^2 - (\sum n)^2}$$

$$\hat{B} = \frac{N \sum n x[n] - (\sum n) (\sum x[n])}{N \sum n^2 - (\sum n)^2}$$

B. 3.2

En la Figura 3 se muestra la evolución de las estimaciones de $\hat{A}$ y $\hat{B}$ en función del número de muestras N .

Puede observarse que, para valores pequeños de N , las estimaciones presentan una dispersión considerable debido a la influencia del ruido sobre una cantidad reducida de observaciones. A medida que N aumenta, las estimaciones convergen hacia los valores reales $A = 2$ y $B = 0.5$, reduciendo su variabilidad.

$$\text{Cov}(\hat{\boldsymbol{\theta}}) = \sigma^2 (\mathbf{H}^T \mathbf{H})^{-1}$$

Por lo tanto, el ajuste obtenido se vuelve más estable y preciso al incrementar N .




Fig. 3. Simulación de los valores estimados en función de N .

C. 3.3

Se asume que los parámetros tienen distribución a priori gaussiana

$$\begin{bmatrix} A \\ B \end{bmatrix} \sim \mathcal{N} \left(\begin{bmatrix} A_0 \\ B_0 \end{bmatrix}, \begin{bmatrix} \sigma_A^2 & 0 \\ 0 & \sigma_B^2 \end{bmatrix} \right)$$

el modelo se representa

$$x = H\theta + w$$

con H hallada anteriormente

y

$$w \sim \mathcal{N}(0, C_w) \quad \text{con} \quad C_w = \sigma^2 I$$

El prior θ puede escribirse como

$$\theta \sim \mathcal{N}(\mu_\theta, C_\theta)$$

Con

$$\mu_\theta = \begin{bmatrix} A_0 \\ B_0 \end{bmatrix}$$

y

$$C_\theta = \begin{bmatrix} \sigma_A^2 & 0 \\ 0 & \sigma_B^2 \end{bmatrix}$$

El estimador MAP se define como

$$\hat{\theta}_{MAP} = \arg \max_{\theta} p(\theta|x)$$

Aplicando el teorema de Bayes:

$$p(\theta|x) = \frac{p(x|\theta)p(\theta)}{p(x)}$$

Como $p(x)$ no depende de θ , maximizar la posteriori es equivalente a maximizar $p(x|\theta)p(\theta)$

Por lo tanto,

$$\hat{\theta}_{MAP} = \arg \max_{\theta} \{p(x|\theta)p(\theta)\}$$

Ya que el ruido es gaussiano:

$$x|\theta \sim \mathcal{N}(H\theta, C_w)$$

La verosimilitud es

$$p(x|\theta) = \frac{1}{(2\pi)^{N/2}|C_w|^{1/2}} \exp\left(-\frac{1}{2}(x - H\theta)^T C_w^{-1}(x - H\theta)\right)$$

Y el prior gaussiano es

$$p(\theta) = \frac{1}{(2\pi)^{|C_\theta|^{1/2}} \exp\left(-\frac{1}{2}(\theta - \mu_\theta)^T C_\theta^{-1}(\theta - \mu_\theta)\right)}$$

Multiplicando ambas expresiones:

$$p(x|\theta)p(\theta) \propto$$

$$\exp\left(-\frac{1}{2}[(x - H\theta)^T C_w^{-1}(x - H\theta) + (\theta - \mu_\theta)^T C_\theta^{-1}(\theta - \mu_\theta)]\right)$$

Como el exponente de la exponencial es negativo, maximizar la posteriori equivale a minimizar el término del exponente:

$$p(\theta) = (x - H\theta)^T C_w^{-1}(x - H\theta) + (\theta - \mu_\theta)^T C_\theta^{-1}(\theta - \mu_\theta)$$

Para encontrar el mínimo, derivamos respecto de θ e igualamos a cero:

$$\frac{\partial p}{\partial \theta} = -2H^T C_w^{-1}(x - H\theta) + 2C_\theta^{-1}(\theta - \mu_\theta) = 0$$

Desarrollando:

$$-2H^T C_w^{-1}x + 2H^T C_w^{-1}H\theta + 2C_\theta^{-1}\theta - 2C_\theta^{-1}\mu_\theta = 0$$

Agrupando términos en θ :

$$(H^T C_w^{-1}H + C_\theta^{-1})\theta = H^T C_w^{-1}x + C_\theta^{-1}\mu_\theta$$

Finalmente, el estimador MAP resulta

$$\hat{\theta}_{MAP} = (H^T C_w^{-1}H + C_\theta^{-1})^{-1} (H^T C_w^{-1}x + C_\theta^{-1}\mu_\theta)$$

Recordando que $C_w^{-1} = \frac{1}{\sigma^2}I$

$$\hat{\theta}_{MAP} = \left(\frac{1}{\sigma^2}H^T H + C_\theta^{-1}\right)^{-1} \left(\frac{1}{\sigma^2}H^T x + C_\theta^{-1}\mu_\theta\right)$$

D. 3.4

Al hacer la comparación experimental del MAP con el MLE para $N = 30$, $\sigma^2 = 2$, $\sigma_A^2 = 1$, $\sigma_B^2 = 3$, $A_0 = 5$, $B_0 = 2$ se obtienen los siguientes resultados a lo largo de las 1000 simulaciones en la Figura 4 Con un resultado final promedio de

$$MSE_{MLE} = 0.240 \quad \wedge \quad MSE_{MAP} = 0.208$$

Se puede ver que el uso de la información a priori reduce el error un 20%.

Esto es un resultado esperable, ya que el estimador MAP usa no solo las observaciones, sino también conocimiento previo acerca de los valores mas probables de A y B .




Fig. 4. Gráfica comparativa de MSE vs MAP

E. 3.5

El parámetro que más se beneficia de la incorporación de información a priori es A .

Esto puede observarse a partir de la matriz de precisión del prior

$$\Sigma_\theta^{-1} = \begin{bmatrix} \frac{1}{\sigma_A^2} & 0 \\ 0 & \frac{1}{\sigma_B^2} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & \frac{1}{3} \end{bmatrix}$$

Como

$$\frac{1}{\sigma_A^2} > \frac{1}{\sigma_B^2}$$

el prior sobre A es más informativo que el de B .

Equivalentemente, como

$$\sigma_A^2 < \sigma_B^2$$

La distribución a priori de A tiene menor varianza, reduciendo el conjunto de valores probables para dicho parámetro. Por lo tanto, el estimador MAP tiene mayor información previa sobre A y su estimación esta mas favorecida por la incorporación del prior.