


Universidad de la República
Facultad de Ingeniería

Estimación y Predicción en Series Temporales

Obligatorio 4

Nombre: Uriel Yaffé
Cédula: 5.318.892.6
Fecha: June 23, 2026



Uriel Yaffé

Small vertical text on the right side of the signature: Escaneo con CamScanner




Fig. 1: Error de estimación $|\hat{a}[n] - a[n]|$ $M = 8$.




Fig. 2: Error de estimación $|\hat{a}[n] - a[n]|$ $M = 16$.

I. EJERCICIO 1

Para la simulación de los datos, dada la canción $a[n]$ y el ruido $v[n]$, se crea $u[n]$ y $x[n]$. $u[n] = h_2 \star v[n]$, $x[n] = a[n] + h_1 \star v[n]$.

A partir de los audios generados, se escucha que el ruido principal ($h_1 \star v[n]$) no es el mismo capturado por la señal auxiliar. Esto es coherente, ya que $h_1 \neq h_2$.

II. EJERCICIO 2 - WIENER

El filtro de Wiener de orden M minimiza el error cuadrático medio

$$E[|x[n] - \mathbf{w}^T \mathbf{u}[n]|^2].$$

La solución óptima satisface las ecuaciones de Wiener-Hopf:

$$\mathbf{R} \mathbf{w} = \mathbf{p}, \quad (1)$$

donde $\mathbf{R} \in \mathbb{R}^{M \times M}$ es la matriz de autocorrelación de $u[n]$, $R_{ij} = \mathbb{E}[u[n-i]u[n-j]]$, y $\mathbf{p} \in \mathbb{R}^M$ es el vector de correlación cruzada,

$$p_i = \mathbb{E}[u[n-i]x[n]].$$

Se observa que al aumentar el orden del filtro de Wiener de ($M=8$) a ($M=16$) disminuye el error de estimación y mejora ligeramente la calidad auditiva de la señal recuperada ($\hat{a}[n]$), tal como se aprecia en las Figuras 1 y 2.

Sin embargo, la cancelación de ruido no resulta completa. Aunque el filtro estimado aproxime adecuadamente la relación entre ambas señales, no puede reproducir exactamente el efecto del canal presente en la grabación original. Por este motivo, la sustracción de señales no logra anular completamente el ruido ambiente.

La aplicación del filtro produce una mejora perceptible en la calidad de la canción, reduciendo parcialmente la interferencia.




Fig. 3: Evolución de los coeficientes del filtro LMS de orden $M = 8$ para distintos valores del parámetro de adaptación α .

No obstante, permanece un ruido residual que se percibe como un sonido de fondo similar a una lluvia con viento continuo.

Por otra parte, al comparar los resultados obtenidos para ($M=8$) y ($M=16$), se observa una reducción mínima del error medio al incrementar el orden del filtro. Sin embargo, esta mejora no resulta apreciable para nada en el audio (comparando $M=8$ con $M=16$). Ya que el error medio absoluto con $M=8$ es 0.0037 y para $M=16$ es 0.003622.

III. EJERCICIO 3 - LMS

El algoritmo LMS (*Least Mean Squares*) es un método de gradiente estocástico que ajusta iterativamente los coeficientes del filtro con el objetivo de minimizar el error cuadrático medio. La actualización de los pesos en cada instante n está dada por

$$e[n] = x[n] - \mathbf{w}^T[n] \mathbf{u}[n], \quad (2)$$

$$\mathbf{w}[n+1] = \mathbf{w}[n] + \alpha e[n] \mathbf{u}[n], \quad (3)$$

donde $e[n]$ es el error de estimación, $\mathbf{u}[n]$ es el vector de entrada y α es el parámetro de adaptación o tamaño de paso.

Para garantizar la convergencia en media del algoritmo, el tamaño de paso debe satisfacer la condición

$$0 < \alpha < \alpha_{\max} = \frac{2}{\text{Tr}(\mathbf{R})},$$

donde $\mathbf{R}$ es la matriz de autocorrelación de la señal de entrada y $\text{Tr}(\cdot)$ su traza.

En las simulaciones se evaluaron distintos valores del tamaño de paso de la forma

$$\alpha = 10^{-b} \alpha_{\max}, \quad b \in \{1, 2, 3, 4\}.$$

A partir de la Figura 8 se que para valores elevados de α , los coeficientes convergen rápidamente hacia la solución, pero oscilan alrededor debido al ruido de gradiente. Por el contrario, al disminuir α , la estabilidad se vuelve más lenta, aunque los pesos presentan una trayectoria más suave y permanecen más próximos a la solución óptima, aunque para valores muy chicos no llega a converger totalmente a la solución.

En el caso de la figura 4, puede observarse que la evolución de los coeficientes presenta oscilaciones muy grandes, lo que impide apreciar claramente su comportamiento temporal.

TABLE I: Error medio absoluto del algoritmo LMS para distintos valores relativos de α .

α	Error medio absoluto ($M = 8$)	Error medio absoluto ($M = 16$)
$\alpha_{\max}$	190746.0217	20.5429
$10^{-1}\alpha_{\max}$	0.0062	0.0064
$10^{-2}\alpha_{\max}$	0.0043	0.0044
$10^{-3}\alpha_{\max}$	0.0042	0.0044

TABLE II: Error medio del algoritmo NLMS para distintos valores de α y longitud del filtro M .

α	Error medio ($M = 8$)	Error medio ($M = 16$)
10^{-1}	0.013656	0.013195
10^{-2}	0.007046	0.006625
10^{-3}	0.004392	0.004383
10^{-4}	0.004102	0.004337

Esto se debe a que se utilizó un valor de paso elevado, ($\alpha = 10^{-1}\alpha_{\max}$), con ($\alpha_{\max} = 1.03 \times 10^{-2}$) (o el valor correspondiente obtenido experimentalmente). Como consecuencia, el algoritmo se encuentra cerca del límite de estabilidad y los pesos exhiben fluctuaciones significativas.

Para ($M=16$) pasa algo similar. En la figura 9 los coeficientes no llegan a converger y la simulación termina produciendo valores numéricamente muy grandes, generando errores de *overflow*. Esto indica que el valor de (α) utilizado es excesivo para garantizar una convergencia estable.

En la figura 10 los coeficientes convergen hacia los valores obtenidos mediante el filtro de Wiener, aunque continúan oscilando alrededor de dichos valores debido a que el α sigue siendo relativamente grande. Al disminuir (α), como se observa en la figura 11, la convergencia se vuelve más estable y los coeficientes alcanzan valores muy próximos a los de Wiener.

Finalmente, en la figura 12, el valor de (α) es demasiado pequeño, por lo que la velocidad de convergencia disminuye considerablemente. Por lo tanto, durante la duración de la señal el algoritmo no tiene suficientes iteraciones para alcanzar los coeficientes óptimos de Wiener.

El comportamiento general replica el de $M=8$ con una leve degradación esperada por mayor dimensión de los filtros.

Mientras que al escuchar cada $\hat{x}$ se puede notar una mejoría en la calidad del audio con respecto a los de Wiener, ya que el ruido que simulaba el sonido de lluvia se escucha más tenue.

También se puede ver en la Tabla I cómo el error medio baja a medida que el α baja, hasta $\alpha_{\max} \cdot 10^{-2}$ y se mantiene.

IV. EJERCICIO 4 - NLMS

El algoritmo NLMS es una variante del LMS estándar en la que el paso de adaptación se normaliza por el vector de entrada:

$$\mathbf{w}[n+1] = \mathbf{w}[n] + \frac{\alpha}{\varepsilon + \|\mathbf{u}[n]\|^2} e[n] \mathbf{u}[n]$$

donde $e[n] = x[n] - \hat{x}[n]$ es el error de predicción en el paso n .

La condición de convergencia para el NLMS es simplemente $0 < \alpha < 2$, a diferencia del LMS, cuyo $\alpha_{\max}$ depende de $\text{Tr}(\mathbf{R})$. En la implementación se usó $\alpha_{\max} = 1$ y se exploraron $\alpha \in \{10^{-1}, 10^{-2}, 10^{-3}, 10^{-4}\}$.

Se puede observar que, al utilizar $\alpha = 10^{-1}\alpha_{\max}$, el algoritmo LMS presenta una divergencia numérica que produce un overflow en la evolución de los coeficientes. En cambio, para el mismo valor relativo, en el algoritmo NLMS no diverge. Como

se aprecia en las Figuras 13 y 17, los coeficientes presentan oscilaciones de gran amplitud alrededor de la solución óptima y no alcanzan una convergencia estable dentro del número de iteraciones considerado. Al escuchar la señal filtrada obtenida con estos parámetros, se percibe principalmente el ruido, mientras que la música puede distinguirse únicamente de forma tenue en segundo plano.

Al igual que en los métodos analizados anteriormente, al disminuir el valor de α se observa una mejora en la convergencia de los coeficientes hacia los correspondientes coeficientes de Wiener, tanto para $M = 8$ como para $M = 16$.

La diferencia más evidente entre LMS y NLMS en los gráficos de pesos es la velocidad de convergencia y la estabilidad en régimen permanente.

El NLMS con $\alpha=0.1$ resuelve el problema de la divergencia: al normalizar por la energía instantánea del vector de entrada, el paso efectivo se autoregula y los pesos convergen visiblemente en las primeras $1 \cdot 10^6$ muestras, manteniéndose luego en torno a sus referencias con varianza moderada. Para $M=8$ esto se ve claramente, mientras que para $M=16$ la convergencia es algo más lenta y la varianza mayor, pero sigue siendo notablemente superior al LMS. A medida que se reduce α en el NLMS, la varianza en régimen permanente baja pero la velocidad de convergencia cae de forma pronunciada. Con $\alpha=1e-03$ o $1e-04$ en NLMS los pesos no alcanzan las referencias dentro de la duración de la señal, comportándose de forma similar al LMS con paso pequeño (Figuras 15, 19, 16 y 20).

En particular, los coeficientes mostrados en la Figura 15 se aproximan bastante a los coeficientes de Wiener. Si bien no alcanzan una convergencia estable dentro del número de iteraciones considerado, las oscilaciones son considerablemente menores que en los casos anteriores y los coeficientes permanecen cercanos a la solución óptima.

V. EJERCICIO 5 - RLS

El algoritmo RLS minimiza recursivamente la suma ponderada de errores cuadráticos pasados con factor de olvido λ :

$$J[n] = \sum_{k=0}^n \lambda^{n-k} e^2[k]$$

La actualización recursiva es:

$$\mathbf{k}[n] = \frac{\mathbf{P}[n-1] \mathbf{u}[n]}{\lambda + \mathbf{u}[n]^\top \mathbf{P}[n-1] \mathbf{u}[n]}$$

$$\mathbf{w}[n] = \mathbf{w}[n-1] + \mathbf{k}[n] e[n]$$

En la Tabla III se puede ver la comparacion del error medio entre los diferentes λ y M .

$$\mathbf{P}[n] = \frac{1}{\lambda} (\mathbf{P}[n-1] - \mathbf{k}[n] \mathbf{u}[n]^\top \mathbf{P}[n-1])$$

se inicializa como $\mathbf{P}[0] = \epsilon \cdot \mathbf{I}$ con $\epsilon=1$.

La diferencia más importante se observa entre los casos $\lambda = 0.99995$ y $\lambda = 0.99$.

Para $\lambda = 0.99995$, tanto en $M = 8$ como en $M = 16$, los coeficientes convergen rápidamente hacia los correspondientes coeficientes de Wiener y posteriormente permanecen oscilando en una pequeña vecindad de la solución óptima. Esto indica que el algoritmo mantiene una estimación estable y aprovecha adecuadamente la información acumulada de las muestras pasadas.

Por el contrario, para $\lambda = 0.99$, los coeficientes presentan fluctuaciones de gran amplitud y no logran converger hacia los valores de Wiener. Las trayectorias ocupan prácticamente todo el rango vertical de las gráficas, evidenciando una elevada sensibilidad al ruido y una pérdida significativa de estabilidad. Este comportamiento sugiere que el factor de olvido es demasiado pequeño para el problema considerado, otorgando un peso excesivo a las muestras más recientes y reduciendo la influencia de la información histórica.

Este comportamiento se debe al factor de decaimiento λ , dada por $k_n = \frac{P_{n-1}u[n]}{\lambda + u^H[n]P_{n-1}u[n]}$. Para $\lambda = 0.99995$, la memoria de los errores es muy grande, lo que reduce la varianza del estimador y favorece la convergencia hacia los coeficientes de Wiener.

En cambio, para $\lambda = 0.99$, la memoria efectiva se reduce significativamente, aumentando la varianza y provocando oscilaciones sin estabilidad.

No se ven diferencias significativas entre los casos $M = 8$ y $M = 16$. Para $\lambda = 0.99$ los pesos, presentan grandes fluctuaciones en ambos casos, sin ver una convergencia estable hacia los coeficientes de Wiener. Por otro lado, para $\lambda = 0.99995$, los coeficientes se estabilizan en torno a los valores óptimos tanto para $M = 8$ como para $M = 16$, además observándose una convergencia muy rápida, antes de la muestra 200.000 todos los coeficientes ya se encuentran prácticamente estabilizados.

Además, se observa una mejora significativa en la supresión del ruido para $\lambda = 0.99995$. En este caso, la señal musical puede apreciarse con mayor claridad, mientras que el ruido queda relegado a un segundo plano de menor intensidad.

Por el contrario, para $\lambda = 0.99$, las fluctuaciones de los coeficientes degradan el desempeño del filtro, la atenuación del ruido es poca y la calidad de la señal recuperada resulta similar o inferior, a la de la señal observada $x[n]$.

Modelo	M	λ	Error medio
RLS	8	0.99995	0.003688
RLS	8	0.99	0.006609
RLS	16	0.99995	0.003665
RLS	16	0.99	0.007391

TABLE III: Error medio del algoritmo RLS para distintos valores de M y λ




Fig. 4: Coeficientes del filtro LMS $M=8$ $\alpha = 10^{-1}\alpha_{\max}$




Fig. 9: Coeficientes del filtro LMS, $M=16$ $\alpha = 10^{-1}\alpha_{\max}$




Fig. 5: Coeficientes del filtro LMS $M=8$ $\alpha = 10^{-2}\alpha_{\max}$




Fig. 10: Coeficientes del filtro LMS, $M=16$ $\alpha = 10^{-2}\alpha_{\max}$




Fig. 6: Coeficientes del filtro LMS $M=8$ $\alpha = 10^{-3}\alpha_{\max}$




Fig. 11: Coeficientes del filtro LMS, $M=16$ $\alpha = 10^{-3}\alpha_{\max}$




Fig. 7: Coeficientes del filtro LMS $M=8$ $\alpha = 10^{-4}\alpha_{\max}$

Fig. 8: Evolución de los coeficientes del filtro LMS de orden $M = 8$ para distintos valores del parámetro de adaptación α .




Fig. 12: Coeficientes del filtro LMS, $M=16$ $\alpha = 10^{-4}\alpha_{\max}$




Fig. 13: Coeficientes del filtro NLMS para $M = 8$ y $\alpha = 10^{-1}\alpha_{\max}$.




Fig. 17: Coeficientes del filtro NLMS para $M = 16$ y $\alpha = 10^{-1}\alpha_{\max}$.




Fig. 14: Coeficientes del filtro NLMS para $M = 8$ y $\alpha = 10^{-2}\alpha_{\max}$.




Fig. 18: Coeficientes del filtro NLMS para $M = 16$ y $\alpha = 10^{-2}\alpha_{\max}$.




Fig. 15: Coeficientes del filtro NLMS para $M = 8$ y $\alpha = 10^{-3}\alpha_{\max}$.




Fig. 19: Coeficientes del filtro NLMS para $M = 16$ y $\alpha = 10^{-3}\alpha_{\max}$.




Fig. 16: Coeficientes del filtro NLMS para $M = 8$ y $\alpha = 10^{-4}\alpha_{\max}$.




Fig. 20: Coeficientes del filtro NLMS para $M = 16$ y $\alpha = 10^{-4}\alpha_{\max}$.




Fig. 21: RLS, $M=8$, $\lambda = 0.99$




Fig. 22: RLS, $M=8$, $\lambda = 0.99995$




Fig. 23: RLS, $M=16$, $\lambda = 0.99$




Fig. 24: RLS, $M=16$, $\lambda = 0.99995$