


Universidad de la República
Facultad de Ingeniería

Estimación y Predicción en Series Temporales

Obligatorio Final

Nombre: Uriel Yaffé
Cédula: 5.318.892.6
Fecha: June 28, 2026



Uriel Yaffé

Small vertical text on the right side of the signature: Escritura de la Universidad de la República

I. EJERCICIO 1 - EMA

Parte 1.1

Partimos del estimador de

$$\theta_{t+1} = (1 - \alpha)\theta_t + \alpha x[t].$$

Tomando esperanza en ambos lados,

$$\mathbb{E}[\theta_{t+1}] = (1 - \alpha)\mathbb{E}[\theta_t] + \alpha\mathbb{E}[x[t]].$$

Como

$$x[t] = \theta + w[t], \quad \mathbb{E}[w[t]] = 0,$$

se tiene que

$$\mathbb{E}[x[t]] = \theta.$$

Luego,

$$\mathbb{E}[\theta_{t+1}] = (1 - \alpha)\mathbb{E}[\theta_t] + \alpha\theta.$$

Desarrollando los primeros términos,

$$\mathbb{E}[\theta_0] = 0, \quad \text{por letra}$$

$$\mathbb{E}[\theta_1] = (1 - \alpha) \cdot 0 + \alpha\theta = \alpha\theta$$

$$\mathbb{E}[\theta_2] = (1 - \alpha)\alpha\theta + \alpha\theta = (2 - \alpha)\alpha\theta = \theta(1 - (1 - \alpha)^2),$$

$$\begin{aligned} \mathbb{E}[\theta_3] &= (1 - \alpha)\mathbb{E}[\theta_2] + \alpha\theta \\ &= (1 - \alpha)\theta(1 - (1 - \alpha)^2) + \alpha\theta \\ &= \theta((1 - \alpha)(1 - (1 - \alpha)^2) + \alpha) \\ &= \theta((1 - \alpha) - (1 - \alpha)^3 + \alpha) \\ &= \theta(1 - (1 - \alpha)^3). \end{aligned}$$

Se observa el patrón

$$\mathbb{E}[\theta_t] = \theta(1 - (1 - \alpha)^t).$$

A. 1.2

El sesgo del estimador es

$$\mathbb{E}[\theta_t] - \theta = \theta(1 - (1 - \alpha)^t) - \theta = -\theta(1 - \alpha)^t.$$

Como para todo $t < \infty$

$$(1 - \alpha)^t \neq 0,$$

el estimador no es insesgado.

Pero,

$$\lim_{t \rightarrow \infty} (1 - \alpha)^t = 0,$$

por lo que

$$\lim_{t \rightarrow \infty} \mathbb{E}[\theta_t] = \theta.$$

Por lo tanto, el estimador es asintóticamente insesgado

Para obtener un estimador insesgado, basta dividir entre el sesgo:

$$\hat{\theta}_t = \frac{\theta_t}{1 - (1 - \alpha)^t}.$$

Por lo tanto

$$\mathbb{E}[\hat{\theta}_t] = \frac{\mathbb{E}[\theta_t]}{1 - (1 - \alpha)^t} = \frac{\theta(1 - (1 - \alpha)^t)}{1 - (1 - \alpha)^t} = \theta.$$

$\hat{\theta}_t$ es un estimador insesgado para todo $t > 0$.

B. 1.3

El modelo de espacio de estados para el filtro de Kalman es

$$x_{n+1} = Fx_n + w_n, \quad w_n \sim \mathcal{N}(0, Q),$$

con

$$F \in \mathbb{R}^{M \times M}, \quad Q \in \mathbb{R}^{M \times M},$$

y el modelo de observación

$$y_n = Cx_n + v_n, \quad v_n \sim \mathcal{N}(0, R),$$

con

$$C \in \mathbb{R}^{N \times M}, \quad R \in \mathbb{R}^{N \times N}.$$

En este problema, el estado x_n representa la constante desconocida θ . Como la constante no varía en el tiempo, el modelo puede escribirse como

$$x_{n+1} = x_n + w_n, \quad w_n \sim \mathcal{N}(0, \sigma_k^2),$$

mientras que el modelo de observación es

$$y_n = x_n + v_n, \quad v_n \sim \mathcal{N}(0, \sigma_w^2).$$

Por lo tanto, los parámetros del modelo son

$$F = 1, \quad Q = \sigma_k^2, \quad C = 1, \quad R = \sigma_w^2.$$

Entonces la recursión de Kalman queda: La corrección

$$\bar{\theta}_t = \bar{\theta}_{t-1} + K_t(y_t - \bar{\theta}_{t-1}) = (1 - K_t)\bar{\theta}_{t-1} + K_t y_t$$

La predicción:

$$\bar{\theta}_t = \hat{\theta}_{t-1}, \quad \bar{P}_t = P_{t-1} + \sigma_k^2$$

La ganancia de Kalman

$$K_t = \frac{\bar{P}_t}{\bar{P}_t + \sigma_w^2} = \frac{P_{t-1} + \sigma_k^2}{P_{t-1} + \sigma_k^2 + \sigma_w^2}$$




Fig. 1: Seguimiento de $\theta = 1$ para filtro de Kalman




Fig. 2: Seguimiento de $\theta = 1$ para filtro EMA

Donde la ecuación recursiva de Kalman queda igual a la de EMA

$$\text{Kalman: } \bar{\theta}_t = (1 - K_t) \bar{\theta}_{t-1} + K_t y_t \quad \text{EMA: } \theta_{t+1} = (1 - \alpha) \theta_t + \alpha y_t$$

La diferencia entre ambas ecuaciones es que en EMA, el α se elige, mientras que en Kalman K_t se calcula automáticamente usando los parámetros e incertidumbres del modelo.

C. 1.4

En la figura 2 se puede ver la evolución de la estimación de θ , con α chico (0.05 y 0.01) la estimación es suave pero muy lenta en converger. Al principio, el sesgo inicial $\theta(1 - \alpha)$ tarda muchas muestras en disiparse. Con α grande (0.3, 0.1) converge más rápido al inicio pero sigue siendo ruidosa incluso al final, ya que el estimador nunca "olvida" el ruido de las




Fig. 3: Seguimiento de $\theta = 1$ para filtro de Kalman sin $\sigma_k^2 = 0.1$

observaciones recientes. Ningún valor de α logra tanto una convergencia rápida y baja varianza al llegar al valor $\theta = 1$.

Con diferencia en la figura 1 se puede ver que en pocas iteraciones del filtro, en todos los valores del ruido, llega a converger al valor esperado. La diferencia entre valores del σ_k^2 es que tanta varianza tiene cuando se mantiene en el valor esperado. Cuando $\sigma_k^2 = 0.1$ se puede ver que la línea roja varía mucho al llegar al valor óptimo.

En la figura 3 se puede ver lo mismo que en la figura 1 sin la línea roja correspondiente a $\sigma_k^2 = 0.1$ que opaca al resto de líneas correspondientes a los otros valores de σ_k^2 . Se puede ver que los valores más bajos de ruido convergen en las mismas iteraciones, pero apenas fluctúan a lo largo de las iteraciones.

D. 2.1

Los factores multiplicativos

$$\frac{1}{1 - \beta^t} \quad \text{y} \quad \frac{1}{1 - \alpha^t}$$

hacen una corrección del sesgo introducido por la inicialización de los promedios en cero. Al igual que en el EMA, durante las primeras iteraciones las estimaciones de m_t y v_t tienden a subestimar los valores reales debido a que aún contienen una fuerte influencia de la condición inicial.

Estos factores compensan el sesgo, obteniendo buenas estimaciones desde las primeras iteraciones. Como se puede ver en la figura 2, para muchos valores de α le tarda bastantes iteraciones en llegar a un valor aproximado al real, ya que el EMA acarrea el ruido de la inicialización en un valor como es en ese caso del 0.

A medida que t aumenta, β^t y α^t tienden a cero, por lo que los factores de corrección tienden a 1 y su efecto desaparece.

E. 2.2

Sea

$$y_t^{(i)} = (\nabla J(\theta_t)[i])^2$$

la observación correspondiente al cuadrado de la i -ésima componente del gradiente. Se asume un modelo de seguimiento de constante

$$v_{t+1}^{(i)} = v_t^{(i)},$$

con observaciones

$$y_t^{(i)} = v_t^{(i)} + w_t, \quad w_t \sim \mathcal{N}(0, \sigma^2).$$

Tomando como inicialización

$$\hat{v}_0^{(i)} = 0, \quad P_0^{(i)} = 1,$$

las ecuaciones del filtro de Kalman univariado son
Predicción

$$\bar{v}_t^{(i)} = \hat{v}_{t-1}^{(i)},$$

$$\bar{P}_t^{(i)} = P_{t-1}^{(i)}.$$

Ganancia

$$K_t^{(i)} = \frac{\bar{P}_t^{(i)}}{\bar{P}_t^{(i)} + \sigma^2}.$$

Corrección

$$\hat{v}_t^{(i)} = \bar{v}_t^{(i)} + K_t^{(i)} \left((\nabla J(\theta_t)[i])^2 - \bar{v}_t^{(i)} \right).$$

Actualización de la covarianza

$$P_t^{(i)} = (1 - K_t^{(i)}) \bar{P}_t^{(i)}.$$

F. 2.3

Como cada coordenada del vector v_t es estimada mediante un filtro de Kalman independiente, la actualización puede escribirse de forma vectorial como

$$K_t = \hat{P}_t / (\hat{P}_t + \sigma^2 \mathbf{1}),$$

$$v_{t+1} = v_t + K_t \odot (g_t^2 - v_t),$$

$$\hat{P}_{t+1} = (1 - K_t) \odot \hat{P}_t,$$

donde $\odot$ y $/$ representan el producto y la división elemento a elemento, respectivamente.

Esta actualización tiene la misma estructura que la utilizada por ADAM,

$$v_{t+1} = v_t + (1 - \alpha)(g_t^2 - v_t),$$

con la diferencia de que en ADAM el peso asignado a la nueva observación es fijo $(1 - \alpha)$, mientras que en Kalmadam el peso es reemplazado por la ganancia adaptativa




Fig. 4: Comparación de optimizadores

K_t . La influencia de las nuevas observaciones depende de la incertidumbre de la estimación y del ruido de observación, permitiendo ajustar la velocidad de actualización de cada coordenada.

II. EJERCICIO 3

Comentario previo: Para la implementación de KalmadamV1 en la última línea cambié `self.d` por `d_hat`, ya que debería ir el momento corregido por el sesgo y no el momento sin corregir (Además que en la implementación de Adam se utiliza la misma ecuación con `d_hat`).

A. 3.2

En la figura 4 se pueden ver los optimizadores SGD, Momentum, RMSProp, ADAM y Kalman.

La primera prueba se realizó con los parámetros por defecto, $\text{STEP} = 1 \cdot 10^{-1}$, $\sigma_v^2 = 0.01$, $\beta = 0.9$, $\text{eps} = 1 \cdot 10^{-8}$

Se puede observar que la trayectoria de los optimizadores intenta seguir el valle de la función de Rosenbrock, el cual conduce al mínimo global. Debido a la forma estrecha y curvada de este valle, los optimizadores sin momentum, como SGD y RMSProp, presentan mayores dificultades para avanzar y permanecen relativamente alejados del mínimo. En cambio, Momentum, ADAM y Kalmadam logran recorrer el valle de manera más efectiva y acercarse mucho más al mínimo global.

Esto también puede apreciarse en las gráficas del error. ADAM reduce rápidamente tanto el valor de la función como la distancia al óptimo, aunque hacia las últimas iteraciones su progreso se vuelve más lento y parece estabilizarse ligeramente antes de alcanzar el mínimo. Por su parte, Momentum continúa descendiendo hasta llegar prácticamente al mínimo global, manteniendo además un comportamiento estable.




Fig. 5: Comparación de optimizadores cambiando a $\beta=0.75$

En el caso de Kalmadam, el algoritmo alcanza la región del mínimo aproximadamente 30 iteraciones antes que Momentum, lo que indica una convergencia muy rápida. Pero, una vez alcanzada la región, comienza a oscilar y termina alejándose del mínimo, incluso saliendo de la superficie representada en la gráfica. Este comportamiento se debe a una inicialización de parámetros que hace que siga de largo del mínimo, debido al STEP o al β que controla el momento, ya que conceptualmente se esperaría un comportamiento similar al de ADAM.

Para la siguiente prueba, con el objetivo de evitar que Kalmadam siga alejándose luego de alcanzar la región del mínimo, se redujo el parámetro β a 0.75. Con este cambio, puede observarse en la Figura 5 que Kalmadam genera un menor efecto de momentum al aproximarse al mínimo, logrando permanecer estable en esa región. Además, en la gráfica correspondiente a xx se aprecia que alcanza un error final muy similar al obtenido por el método de Momentum.

En este experimento, el método de Momentum presenta el comportamiento más estable, lo cual resulta esperable dado que la función de Rosenbrock posee un único mínimo global y un valle relativamente suave, por lo que un mecanismo de momentum favorece el avance a lo largo de dicho valle sin necesidad de una adaptación agresiva del tamaño de paso.

Luego decidí cambiar la función objetivo a la de Ackley, la cual se la refiere como "Es una especie de mezcla entre una parábola y una huevera, llena de mínimos locales".

Se volvieron a utilizar los parámetros por defecto en la figura 6, $STEP = 1 \cdot 10^{-1}$, $\sigma_v^2 = 0.01$, $\beta = 0.9$, $eps = 1 \cdot 10^{-8}$

En la Figura 6 puede observarse que los optimizadores SGD y Momentum son los primeros en quedar atrapados en un mínimo local. En el caso de SGD, esto se debe a que utiliza únicamente el gradiente instantáneo, mientras que Momentum




Fig. 6: Comparación de optimizadores, función Ackley

incorpora un término de momento constante que, en este caso, no resulta suficiente para escapar de dicho mínimo.

Por otro lado, ADAM y RMSProp logran superar ese mínimo local y continúan avanzando hacia la región del mínimo global, alcanzando valores de la función objetivo considerablemente menores. Ya que RMSProp adapta el paso para cada coordenada y Adam junta la normalización del paso con el momentum.

En el caso de Kalmadam, el comportamiento observado es diferente. Debido a la configuración de sus parámetros, el optimizador comienza a recorrer distintas regiones alrededor del mínimo global con una trayectoria oscilatoria, sin llegar a estabilizarse rápidamente. Sin embargo, hacia el final de las iteraciones consigue alcanzar un valor de la función objetivo inferior a la de los demás métodos, aunque sin mostrar estabilidad durante las iteraciones.

En la Figura 7 se realizó el mismo experimento que en la Figura 6, con la diferencia de que nuevamente se redujo el coeficiente de momentum a $\beta=0.75$. Este cambio permitió que el optimizador Kalmadam presentara un comportamiento mucho más estable durante las iteraciones, logrando alcanzar la región del mínimo global sin las oscilaciones observadas en el experimento anterior.

Además, puede apreciarse que, durante gran parte del proceso de optimización, Kalmadam mantiene tanto un error $||x-x^*||$ como una diferencia en el valor de la función objetivo $f-f^*$ inferiores a los obtenidos por los demás optimizadores.

Para mejorar la convergencia hacia el mínimo, se observó que al ingresar a la región cercana al mínimo global (caracterizada por una alta pendiente) el algoritmo comienza a oscilar alrededor de dicha zona. Esto explica que en la Figura 7, durante las últimas iteraciones, tanto el error como la distancia




Fig. 7: Comparación de optimizadores, función Ackley con $\beta = 0.75$

a la función objetivo vuelvan a aumentar considerablemente.

Para mitigar este comportamiento, se redujo el parámetro STEP a la mitad, fijándolo en $STEP = 5 \cdot 10^{-2}$, como se muestra en la Figura 8. Esta modificación permite una convergencia más estable, donde en las últimas iteraciones el error disminuye de forma progresiva hasta llegar prácticamente al mínimo global.

Estos resultados muestran que combinar el momento corregido con una normalización adaptativa tipo filtro de Kalman puede mejorar el rendimiento del algoritmo frente a otros métodos del experimento.

Igualmente, el comportamiento depende bastante de cómo se eligen los parámetros, así que una buena calibración es clave para obtener buenos resultados.




Fig. 8: Comparacion de optimizadores, funcion Ackley con $\beta = 0.75$ y $STEP=5 \cdot 10^{-2}$